

# Classification du Cancer du Sein

## Techniques d'Apprentissage Artificiel

Bademba SANGARE

Université Paris 8  
Master 1 Informatique et Big Data

10 décembre 2025

Professeur : Rakia JAZIRI

# Plan de la Présentation

- 1 Introduction
- 2 Méthodologie
- 3 Apprentissage et Modèles
- 4 Résultats & Analyse
- 5 Conclusion

## Contexte : Apprentissage Supervisé

Nous disposons d'un jeu de données **\*\*étiqueté\*\*** (nous connaissons le diagnostic réel). Le but est d'entraîner un modèle à prédire cette étiquette pour de nouveaux patients.

### Les Classes (Cibles)

- **Maligne (M)**
  - = **Malade**
  - = Positif (1)
- **Bénigne (B)**
  - = **Non Malade (Sain)**
  - = Négatif (0)

### Objectif

- Le modèle doit pouvoir dire avec certitude si un patient est **Maligne** ou **Bénigne** en analysant les caractéristiques de la tumeur.

# Le Jeu de Données (Dataset)

Source : Kaggle - Breast Cancer Wisconsin (569 patients)

## Répartition des patients :


- **357 Bénignes** (Non Malades)
  - Soit **62.7%** du total
- **212 Malignes** (Malades)
  - Soit **37.3%** du total

## Exemples de caractéristiques :

- `radius_mean` : Rayon moyen
- `texture_mean` : Texture
- `perimeter_mean` : Périmètre

ID	Diagnosis	Radius	Texture	...
842302	M	17.99	10.38	...
842517	M	20.57	17.77	...
84300903	M	19.69	21.25	...

# Pipeline de Traitement



- **Split Train/Test (80/20) :**
  - **80% Entraînement** : Pour que le modèle apprenne.
  - **20% Test** : Données cachées pour évaluer la performance réelle.
- **Stratification** : On garde les mêmes proportions de malades dans les deux groupes.
- **Normalisation** : Indispensable pour mettre les données à la même échelle.

# Les 3 Algorithmes Étudiés

- **Random Forest (Focus)** :

Une "forêt" de 100 arbres de décision. C'est notre modèle principal car il est robuste et stable.


- **SVM (Support Vector Machine)** :

Cherche la "frontière" optimale entre les deux groupes (Malades et Sains).

- **KNN (K-Nearest Neighbors)** :

Regarde les **5 voisins** les plus proches. Simple mais sensible aux valeurs aberrantes (outliers).

# Détail du calcul (Random Forest)



**Données :** Vrais Positifs=39, Vrais Négatifs=72, Faux Positifs=0, Faux Négatifs=3

## 1. Accuracy

L'accuracy, c'est simplement le nombre de bonnes prédictions divisé par le total : 39 plus 72 sur 114 égale 97,37%.

## 2. Precision



La precision, c'est les vrais positifs sur les vrais positifs plus les faux positifs : 39 sur 39 plus 0 égale 100%.

## 3. Recall


Et le recall, c'est les vrais positifs sur les vrais positifs plus les faux négatifs : 39 sur 42 égale 92,86%.

**3 Faux Négatifs** = point critique à améliorer  
**0 Faux Positifs** = aucune fausse alerte

# Comparaison Visuelle des Modèles



# Performance Globale



## Tableau des Scores

Modèle	Acc.	Prec.	Rec.	F1	AUC
Random Forest	0.9737	1.0000	0.9286	0.9630	0.9929
SVM	0.9737	1.0000	0.9286	0.9630	0.9947
KNN	0.9561	0.9744	0.9048	0.9383	0.9823

## Pourquoi ces résultats ?

- **RF et SVM (Top)** : Ils sont excellents pour gérer la complexité et les nombreuses dimensions (30 features) sans sur-apprendre.
- **KNN (En retrait)** : Basé sur la distance brute, il souffre plus du bruit ou des données isolées (outliers).

# Conclusion

## Bilan

- **Random Forest** est le modèle retenu.
- Il offre une précision de 100% (aucune fausse alerte).
- Le Recall de 92.8% signifie qu'on a raté 3 cas sur 42 : c'est le point d'amélioration prioritaire pour une application médicale réelle.

**Merci de votre attention.**